고객 행동 데이터로 보는 카드 상품 전략

by EXODIA

목차

1. 분석 배경

2. 데이터 구조 및 분석 환경

3. 데이터 이해

4. 모델 구축

5. Frontend 구축

6. 고객 세그먼트 및 분석

7. 카드 상품 라인업 전략

8. 결론

1. 분석 배경

카드사는 **다양한 카드 상품 라인업**을 운영

이러한 카드 상품의 차이는

- **단순한 혜택 차이?**
- **고객 행동 기반 전략?**

⇒ 고객 행동 데이터 기반 상품 전략

2. 데이터 구조 및 분석 환경

Docker로 구성된 아키텍쳐

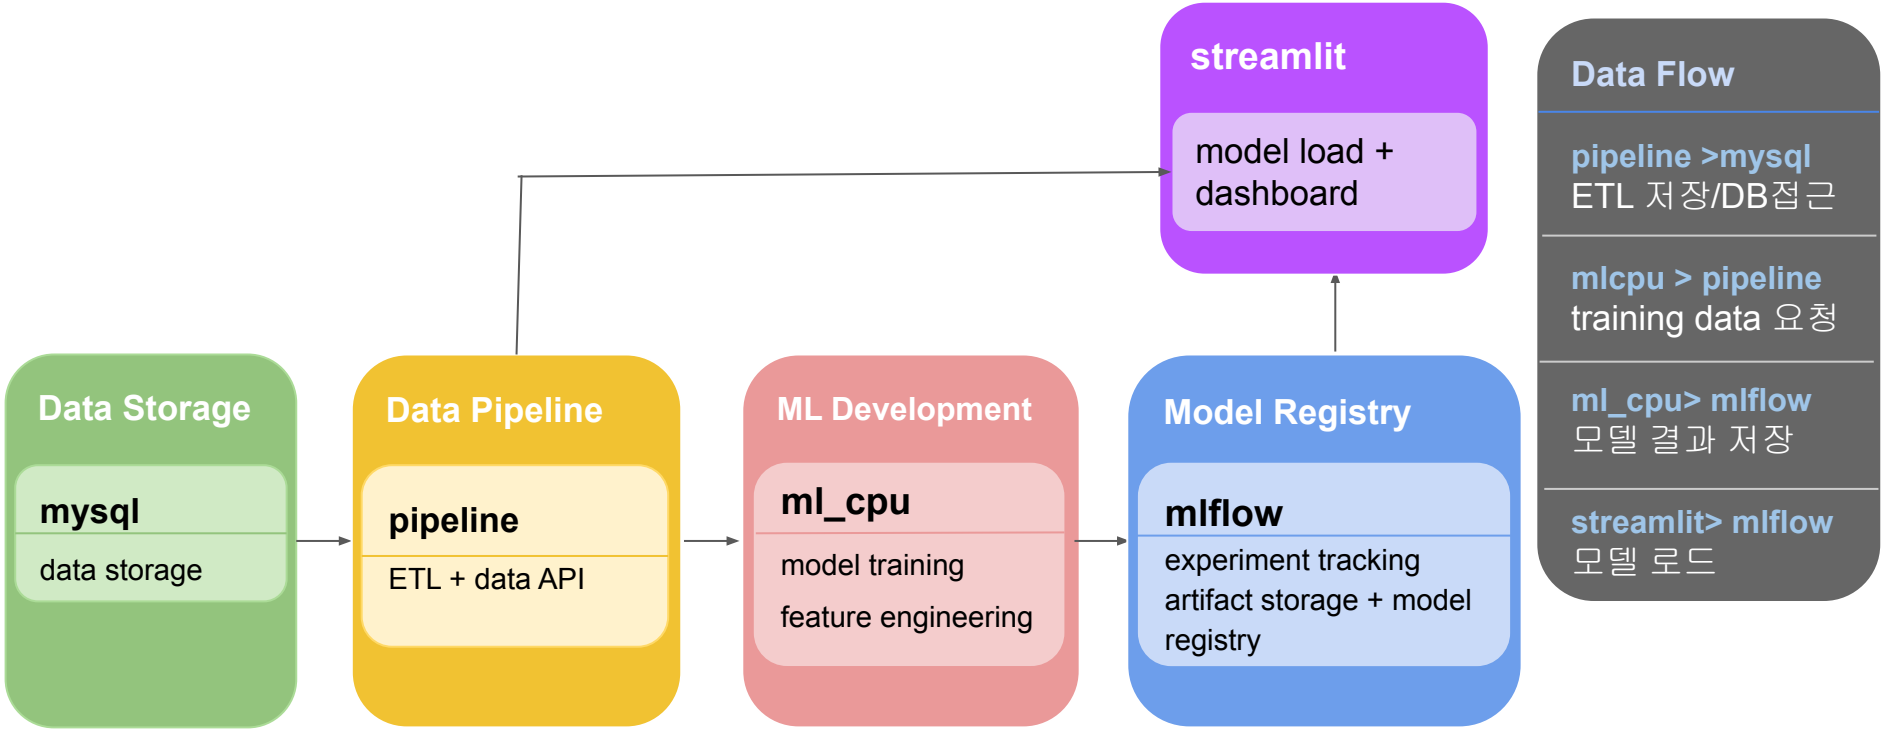

2. 데이터 구조 및 분석 환경

Docker Compose

- 앱 실행 환경 통일 시스템
- 실행 환경을 기록하는 image, 구축된 환경 container

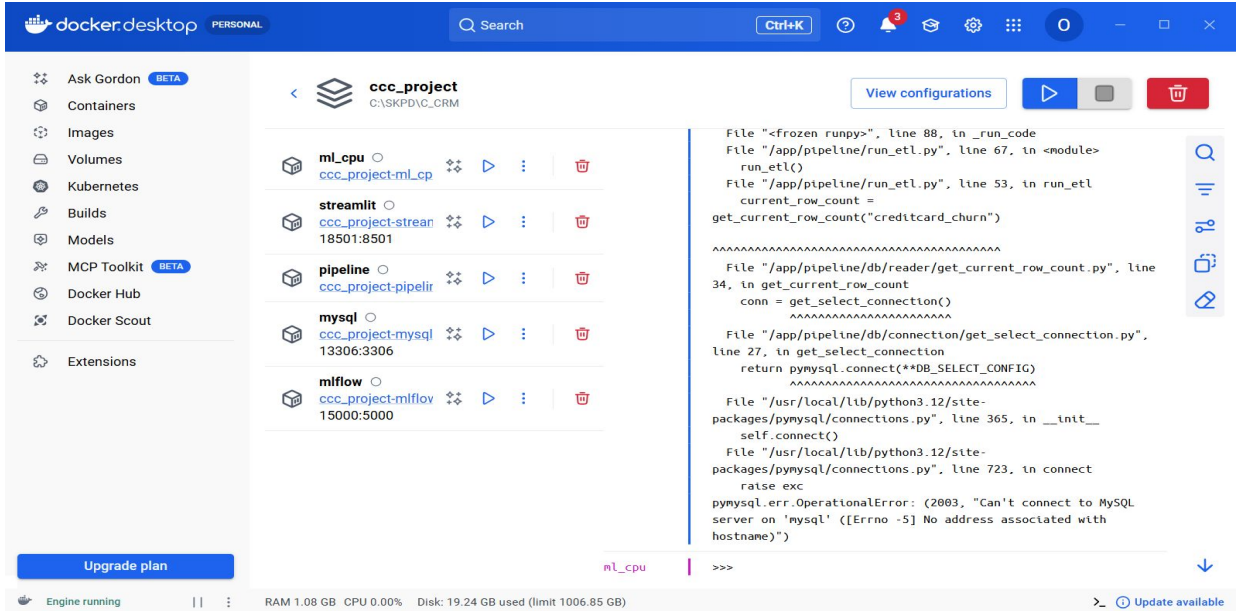

2. 데이터 구조 및 분석 환경

FastAPI

- Python 기반 API 서버를 구축 프레임워크
- Database에 적재했던 데이터를 호출

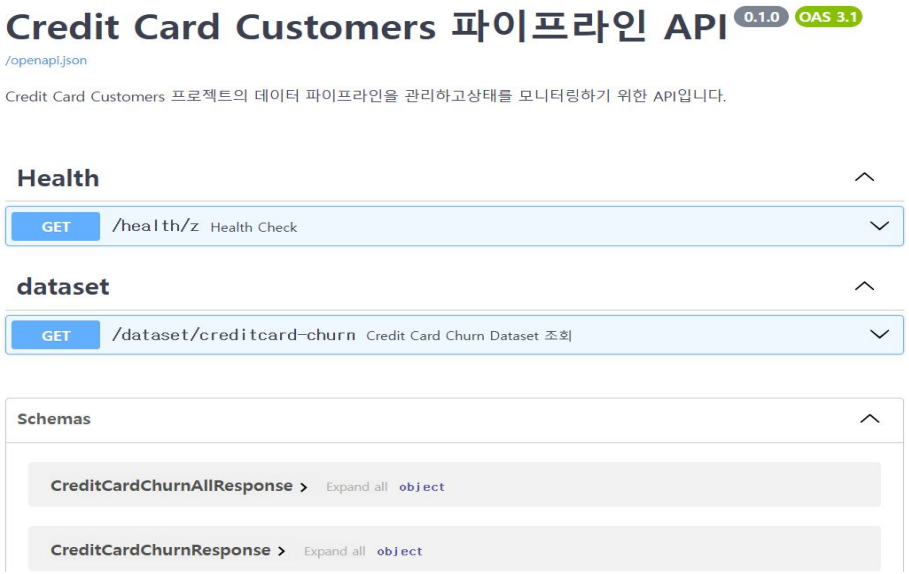

2. 데이터 구조 및 분석 환경

Data Pipeline

- Credit Card Customers Dataset을 전처리
- MySQL을 활용해서 데이터셋 적재

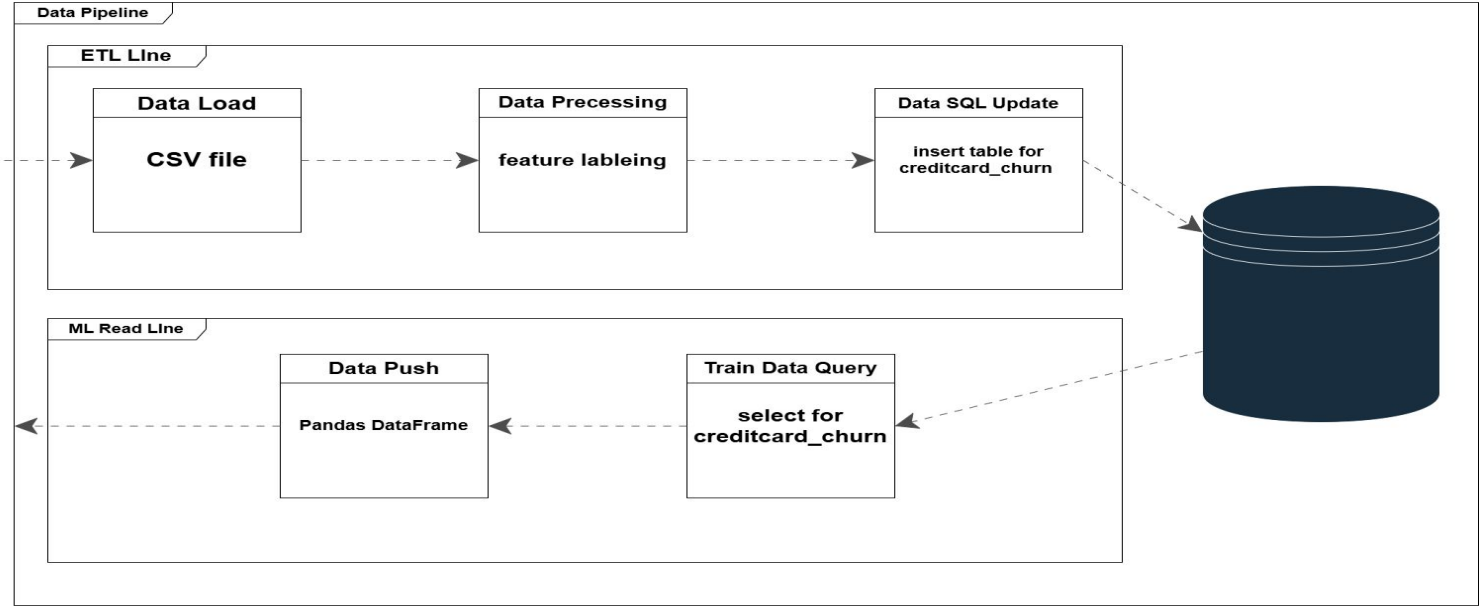

2. 데이터 구조 및 분석 환경

MLflow

- 머신러닝 모델 관리 오픈소스 머신러닝 플랫폼
- 모델의 추적, 결과 기록, 모델의 배포 등

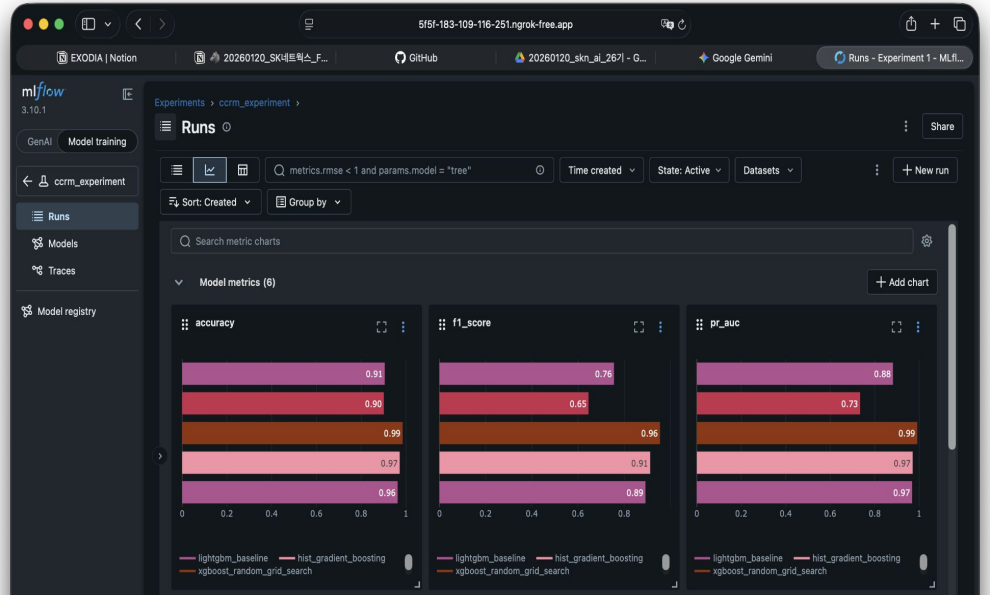

2. 데이터 구조 및 분석 환경

프로젝트 ERD

- 고객 테이블 중심
- Feature Tabling 구조

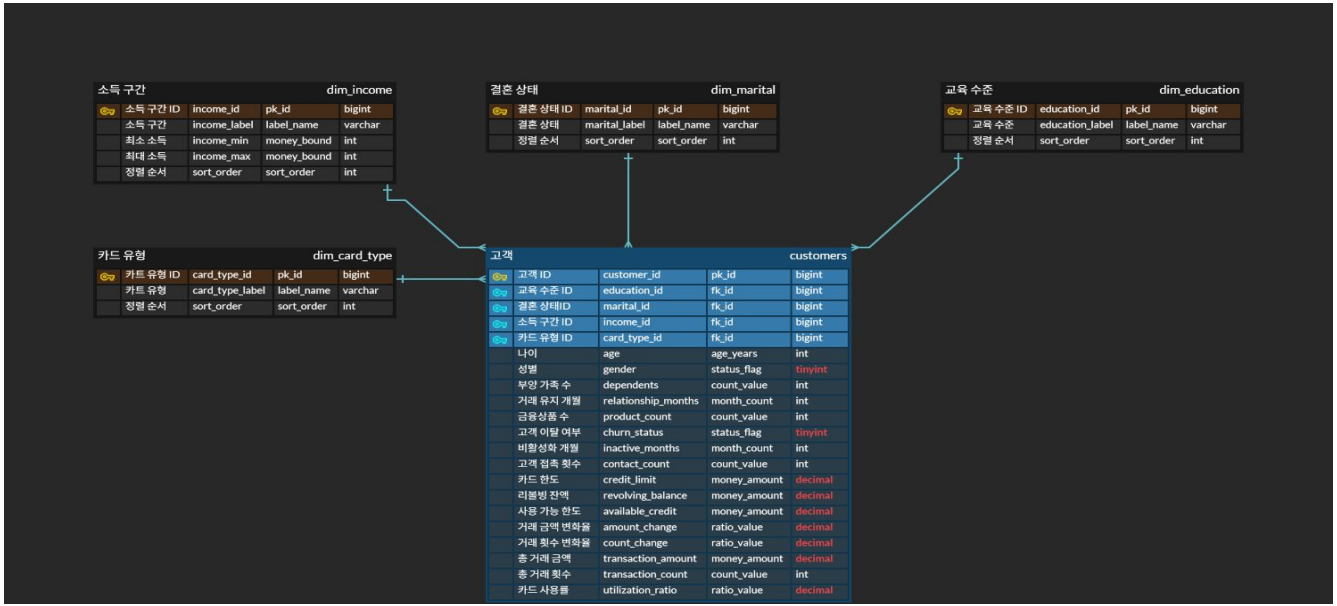

3. 데이터 이해

EDA

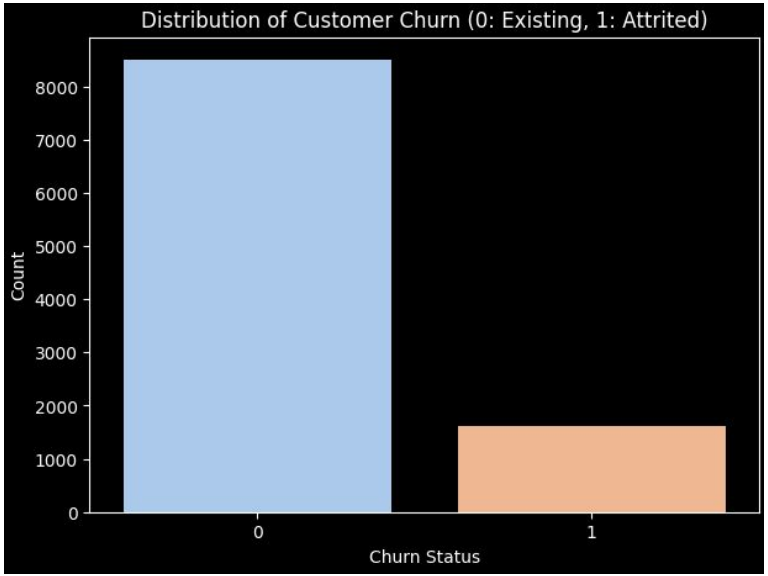

churn 고객 비율

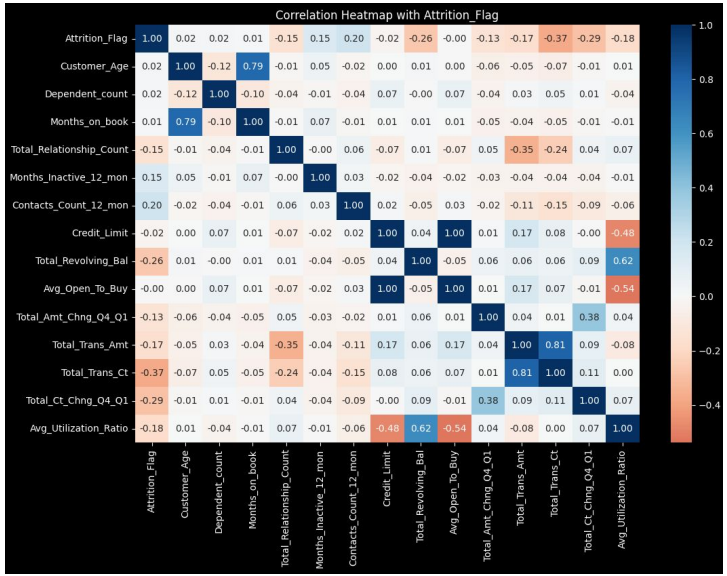

컬럼 Heatmap

이탈 고객 15%에 대한 분석에 집중

3. 데이터 이해

EDA

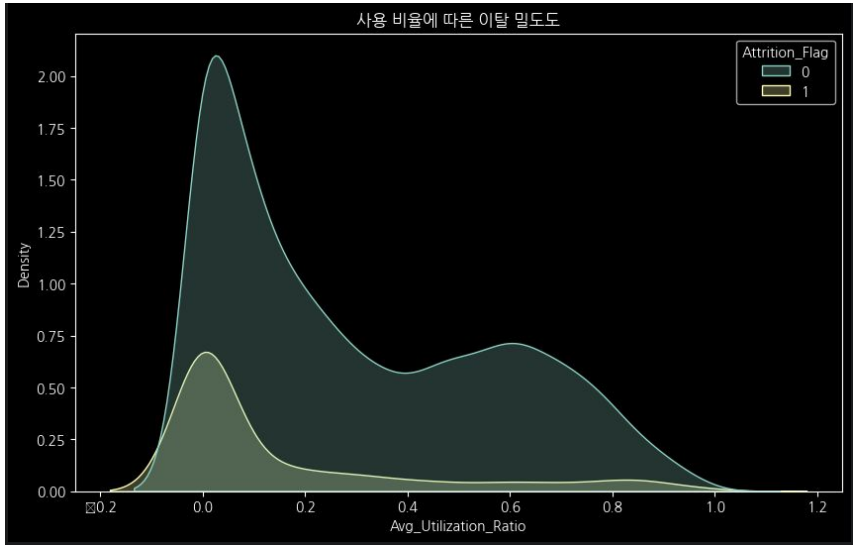

사용률에 따른 이탈 분포

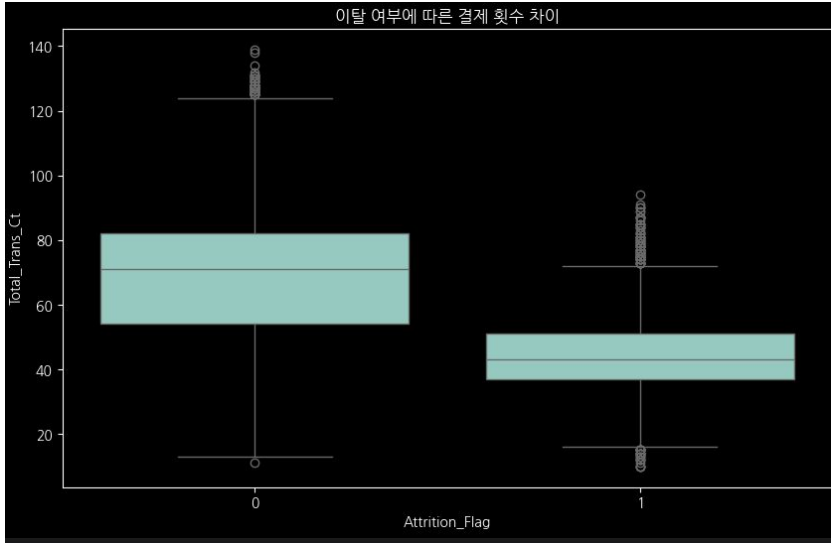

churn 여부 별 사용률

한도 사용률이 낮을수록 churn 비율 높음

3. 데이터 이해

EDA

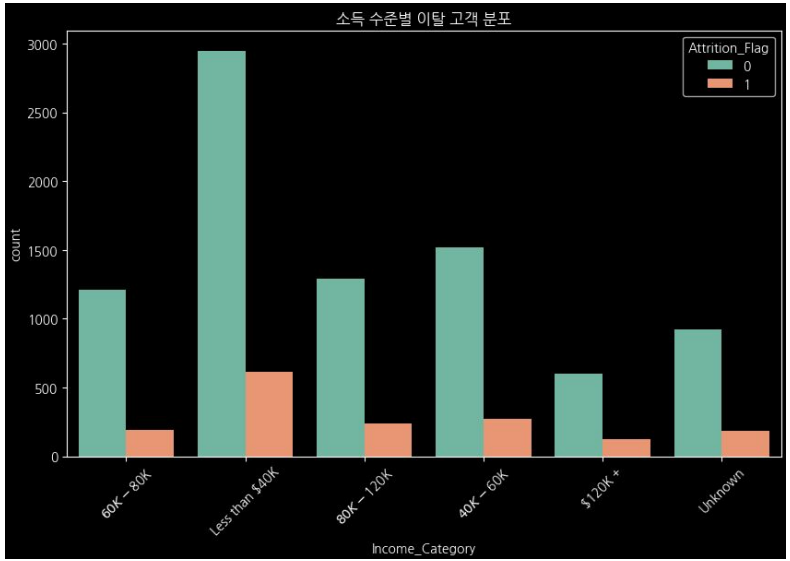

소득 수준 이탈 분포

학력/소득 수준 heatmap

학력과 소득수준 연관성이 적음

3. 데이터 이해

결측치 예측

- LDA 차원 축소를 통해 다른 컬럼과 관계 확인
- 모델 사용을 통해 결측치 예측

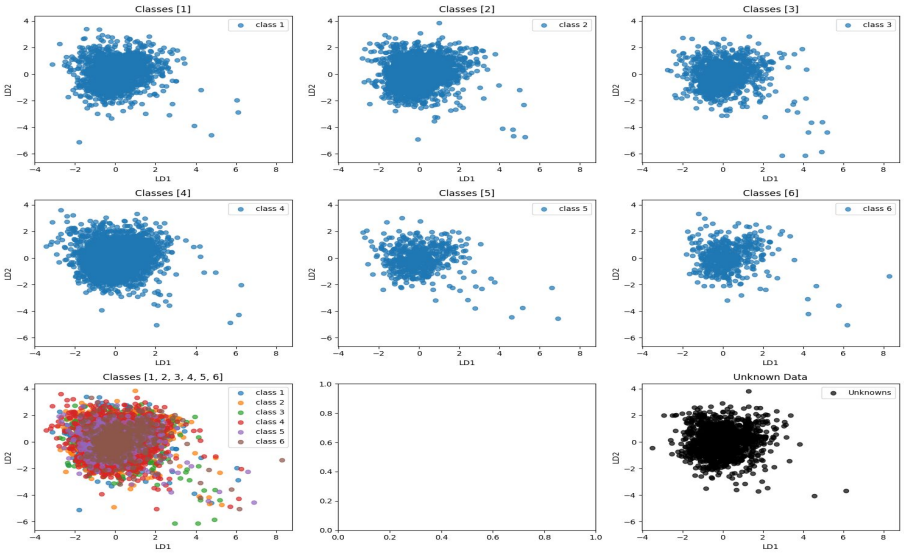

education_level LDA scatter plot

3. 데이터 이해

결측치 예측

- class 1, 2와 3, 4, 5간의 유사성을 확인
- **2구간, 3구간 사이의 임계점**이 존재
- income 기준 사용자군 분할
- 모델 사용을 통해 추가적인 예측

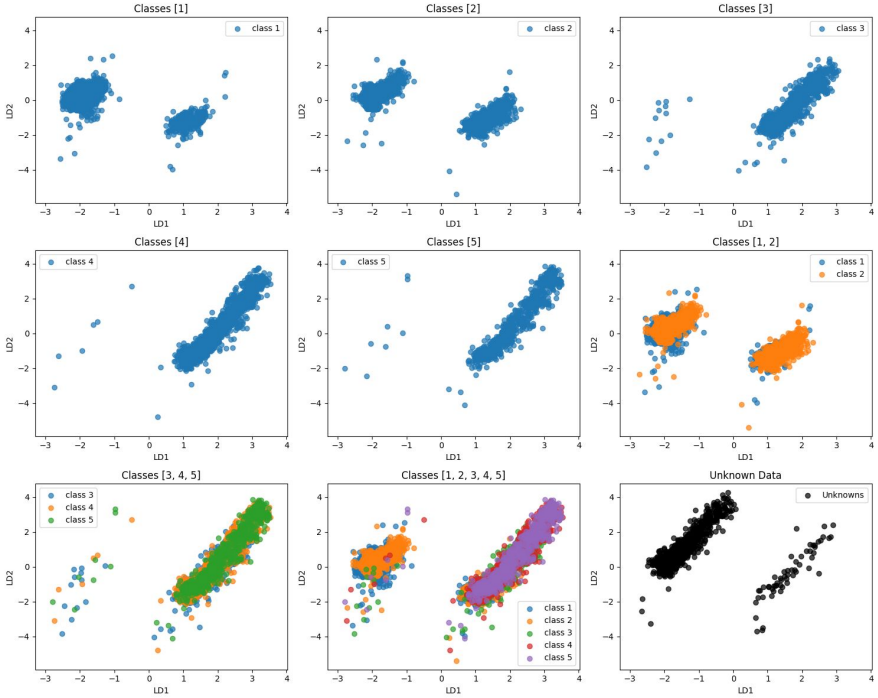

income_level LDA scatter plot

3. 데이터 이해

Classification (1, 2, 3, 4, 5)

```
==================== Train ====================
        target type: multiclass
           accuracy: 0.570095
             recall: 0.435595
                 f1: 0.402960
            roc_auc: 0.822349
             pr_auc: 0.461531
    precision_score: 0.475841
==================== Test ====================
        target type: multiclass
           accuracy: 0.551895
             recall: 0.415238
                 f1: 0.383478
            roc_auc: 0.807715
             pr_auc: 0.436092
    precision_score: 0.453150
```

Logistic Regression

```
==================== Train ====================
        target type: multiclass
           accuracy: 0.536043
             recall: 0.377910
                 f1: 0.319694
            roc_auc: 0.822349
             pr_auc: 0.461531
    precision_score: 0.454747
==================== Test ====================
        target type: multiclass
           accuracy: 0.535420
             recall: 0.376114
                 f1: 0.319808
            roc_auc: 0.807715
             pr_auc: 0.436092
    precision_score: 0.455818
```

Random Forest Classifier

3. 데이터 이해

Classification (0, 1)

```
==================== Train ====================
        target type: binary
           accuracy: 0.886036
             recall: 0.958950
                 f1: 0.872894
            roc_auc: 0.953141
             pr_auc: 0.929241
    precision_score: 0.801012
==================== Test ====================
        target type: binary
           accuracy: 0.886875
             recall: 0.969044
                 f1: 0.874848
            roc_auc: 0.947883
             pr_auc: 0.925117
    precision_score: 0.797342
```

Logistic Regression

```
==================== Train ====================
        target type: binary
           accuracy: 0.874777
             recall: 0.866083
                 f1: 0.849505
            roc_auc: 0.953141
             pr_auc: 0.929241
    precision_score: 0.833549
==================== Test ====================
        target type: binary
           accuracy: 0.857221
             recall: 0.845222
                 f1: 0.828496
            roc_auc: 0.947883
             pr_auc: 0.925117
    precision_score: 0.812419
```

Random Forest Classifier

4. 모델 구축

사용 모델

- **Logistic Regression:** 클래스에 속할 확률을 sigmoid로 모델링, 선형 회귀
- **Easy Ensemble:** 다수 클래스를 언더샘플링, 클래스 불균형 문제를 해결
- **LightGBM:** Gradient Boosting 기반 결정 트리 모델
- **Hist Gradient Boosting:** 입력 데이터를 bin으로 분할하는 결정 트리
- **XGBoost:** 병렬 처리, pruning을 활용한 Gradient Boosting Decision Tree 라이브러리

4. 모델 구축

사용 지표

- **Accuracy:** 전체 예측 중에서 맞게 예측한 비율
- **Precision:** Positive로 예측한 것 가운데 실제 Positive인 비율
- **Recall:** 실제 Positive를 맞춘 비율
- **F1 Score:** Precision, Recall의 조화 평균
- **ROC-AUC:** ROC Curve 아래 면적
- **PR-AUC:** Precision Recall Curve 아래 면적

Recall과 PR-AUC를 중점으로 모델 평가

4. 모델 구축

하이퍼 파라미터 튜닝

```python
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import HistGradientBoostingClassifier

model = HistGradientBoostingClassifier(random_state=42, early_stopping=True, n_iter_no_change=20)

# 최적의 경우를 찾고자 하는 하이퍼 파라미터들을 dictionary 형태로 준비
params = {
    'max_iter':[100, 200, 300],    # 약학습기 개수
    'validation_fraction':[0.03, 0.05, 0.08], # 일정 비율을 검증용 데이터로 사용
}

# GridSearchCV 적용
grid_search = GridSearchCV(model, param_grid=params, cv=5, scoring='average_precision')
grid_search.fit(train_X, train_y)

# 어떤 parameter를 전달했을 때 가장 좋은 결과를 얻을 수 있는지
print(grid_search.best_params_)
# 그때의 score
print(grid_search.best_score_)
# 해당 parameter를 전달한 학습 모델
print(grid_search.best_estimator_)
```

Python

Grid Search CV, PR-AUC를 활용한 하이퍼 파라미터 튜닝

4. 모델 구축

Logistic Regression

Search metrics

Metric	Value
accuracy	0.9012707722385142
precision	0.7829787234042553
recall	0.5492537313432836
f1_score	0.6456140350877193
roc_auc	0.9057372401580641
pr_auc	0.734114877041733

예측 정확도 0.54~0.90

4. 모델 구축

Easy Ensemble

Search metrics

Metric	Value
accuracy	0.9051808406647116
precision	0.6535947712418301
recall	0.8955223880597015
f1_score	0.7556675062972292
roc_auc	0.9642907612725385
pr_auc	0.8819480651822453

예측 정확도 0.65~0.96

4. 모델 구축

LightGBM

Search metrics

Metric	Value
accuracy	0.9628543499511242
precision	0.8509485094850948
recall	0.9373134328358209
f1_score	0.8920454545454546
roc_auc	0.9897799139893751
pr_auc	0.9681245897874674

예측 정확도 0.85~0.98

4. 모델 구축

Hist Gradient Boosting

Search metrics

Metric	Value
accuracy	0.966275659824047
precision	0.934640522875817
recall	0.8537313432835821
f1_score	0.8923556942277691
roc_auc	0.9917478649999565
pr_auc	0.9657842996597066

예측 정확도 0.85~0.99

4. 모델 구축

XGBoost

Search metrics

Metric	Value
accuracy	0.9853372434017595
precision	0.9579579579579579
recall	0.9522388059701492
f1_score	0.9550898203592815
roc_auc	0.9983094463393145
pr_auc	0.9911738345429559

예측 정확도 0.95~0.99

5. Frontend 구축

Streamlit 구현

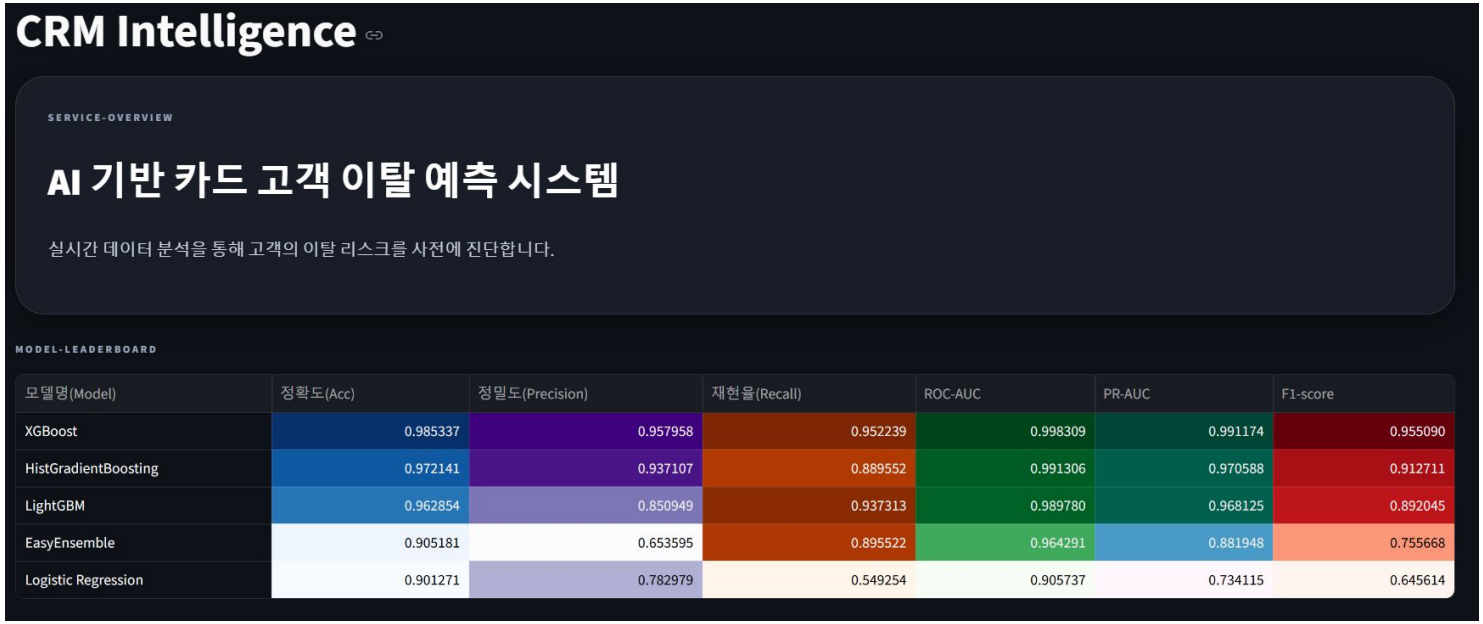

모델명(Model)	정확도(Acc)	정밀도(Precision)	재현율(Recall)	ROC-AUC	PR-AUC	F1-score
XGBoost	0.985337	0.957958	0.952239	0.998309	0.991174	0.955090
HistGradientBoosting	0.972141	0.937107	0.889552	0.991306	0.970588	0.912711
LightGBM	0.962854	0.850949	0.937313	0.989780	0.968125	0.892045
EasyEnsemble	0.905181	0.653595	0.895522	0.964291	0.881948	0.755668
Logistic Regression	0.901271	0.782979	0.549254	0.905737	0.734115	0.645614

모델 예측 결과 리포트

5. Frontend 구축

Streamlit 구현

개별 사용자 예측 기능

5. Frontend 구축

Streamlit 구현

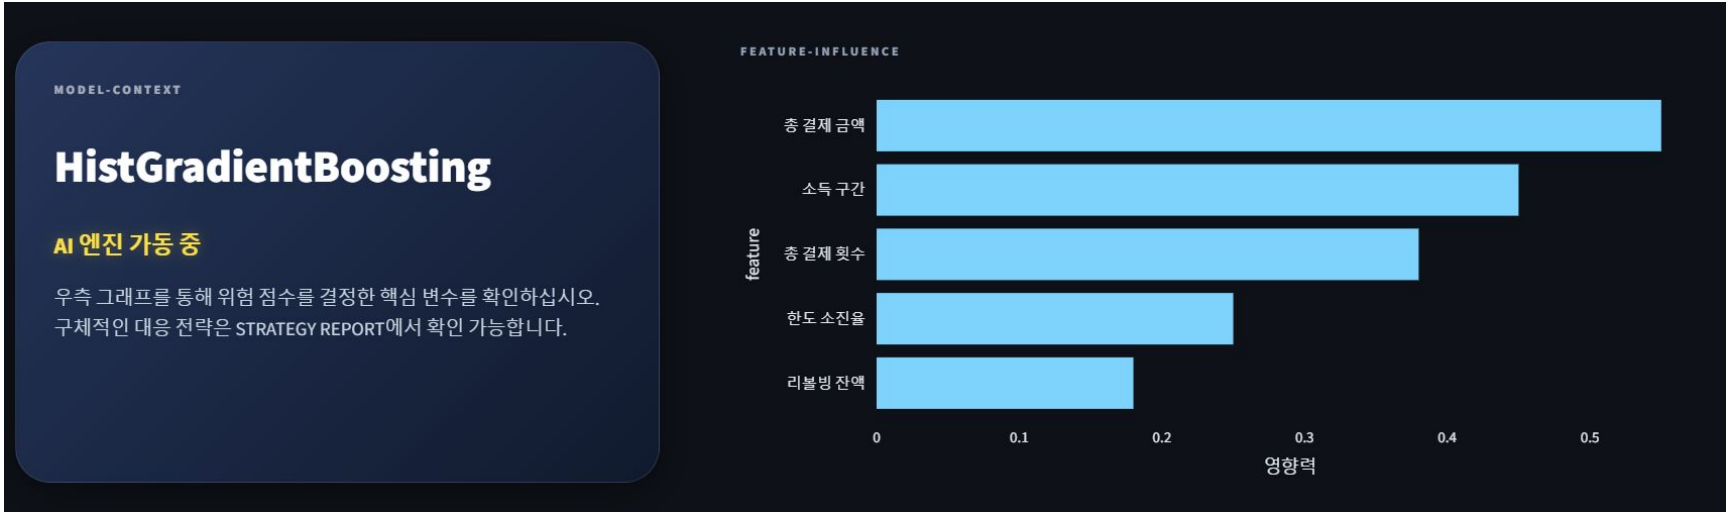

모델 feature weight 시각화

5. Frontend 구축

Streamlit 구현

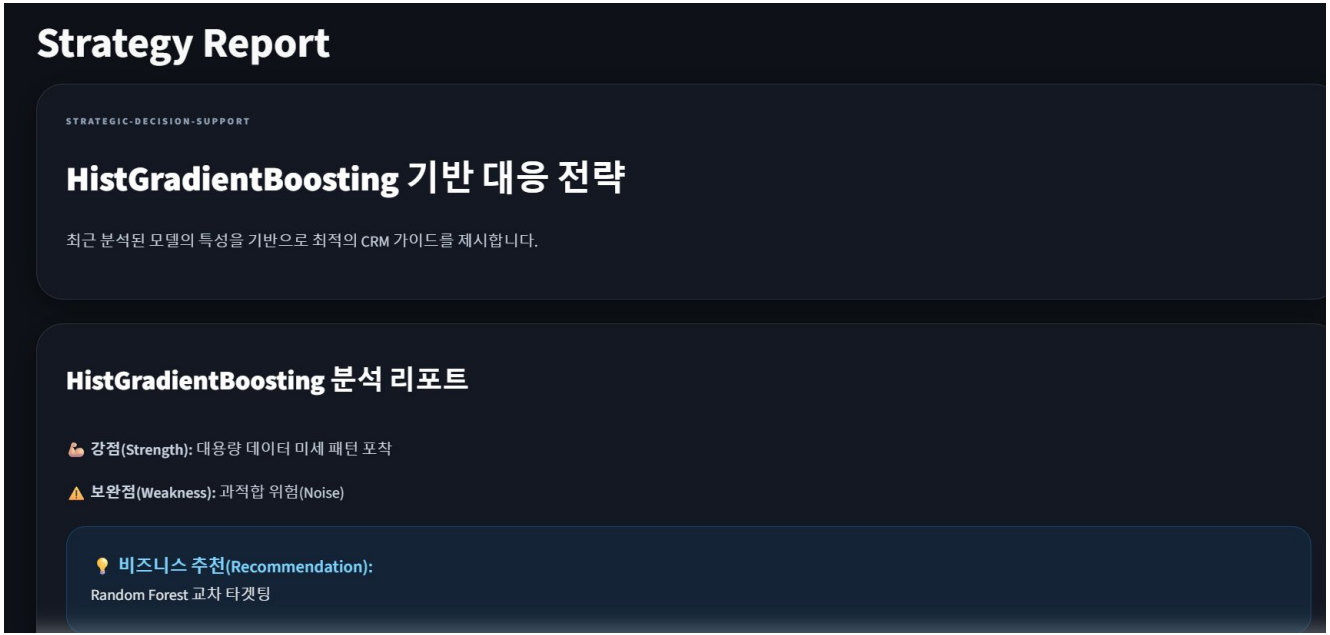

모델에 따른 전략 기획서 제공

5. Frontend 구축

Streamlit 구현

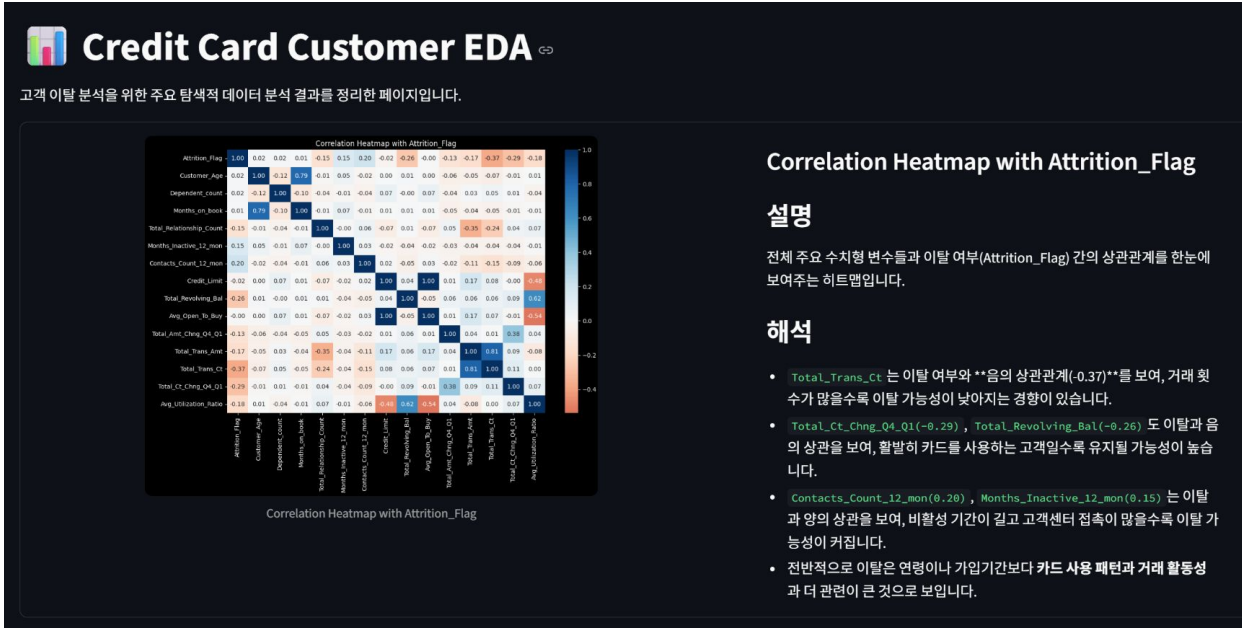

DB 데이터 기반 EDA

5. Frontend 구축

Streamlit 구현

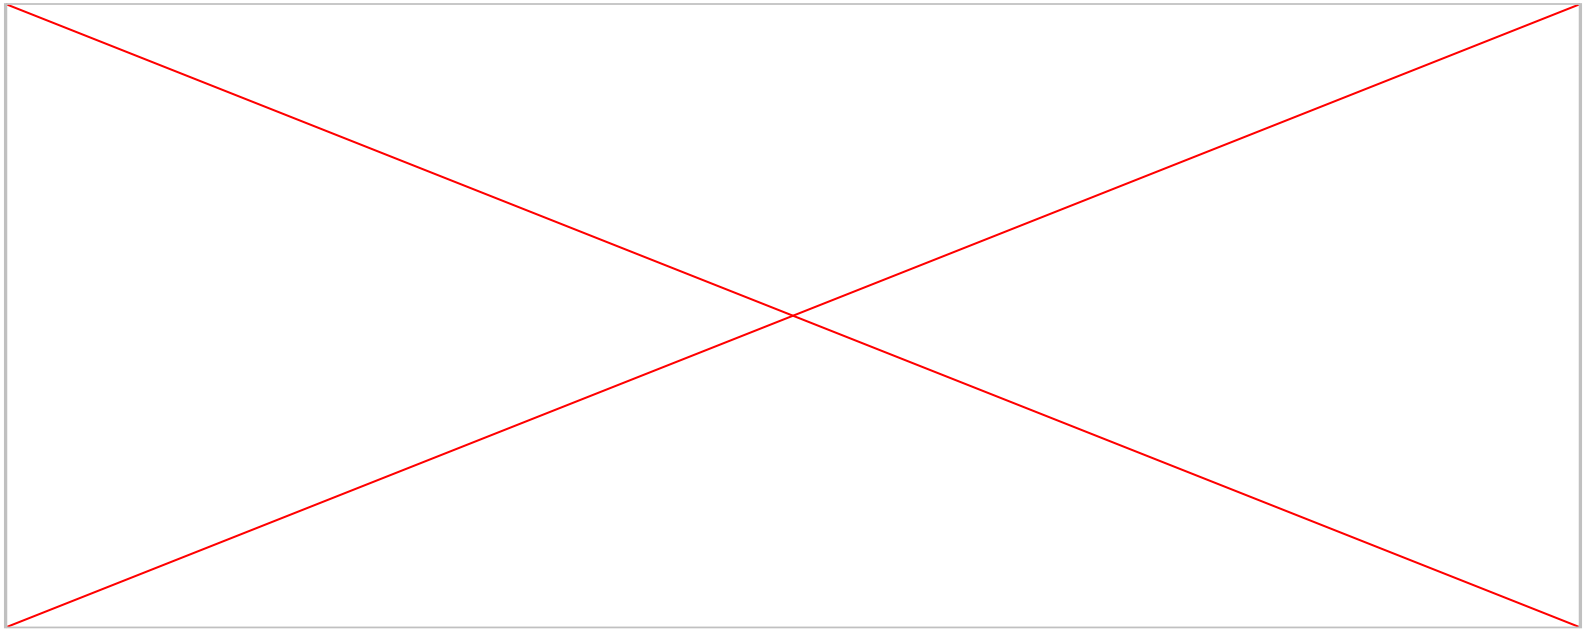

시연 영상

5. Frontend 구축

Figma Mockup

사용자 페이지

Figma QR

6. 고객 세그먼트 및 분석

이탈과 유지

소결:

이탈 고객 약 15% / **유지 고객 약 85%**

카드 거래량 규모 작을 수록 이탈 확률 상승

카드 이용은 카드사 간 **혜택 경쟁 구조 속에서 발생**

→ 실적 조건과 혜택을 통해 사용 유지 유도

6. 고객 세그먼트 및 분석

이탈과 유지

- **기존 접근**
  고객 이탈 분석 중심

- **관점 전환**
  이탈 = 카드 사용 중지
  유지 = 카드 이용 지속

→ **고객 유지 행동을 기준으로 고객 세그먼트를 정의**

6. 고객 세그먼트 및 분석

고객 카드 이용 활동 데이터 분석

핵심 변수

- 거래 빈도 Transaction Count
- 소비 규모 Transaction Amount
- 신용 한도 Credit Limit

보조 변수

- 사용률 Utilization Ratio
- 미사용 개월 Inactive Months

6. 고객 세그먼트 및 분석

세그먼트 계층

Activity Score 기반 4개 고객 세그먼트 정의

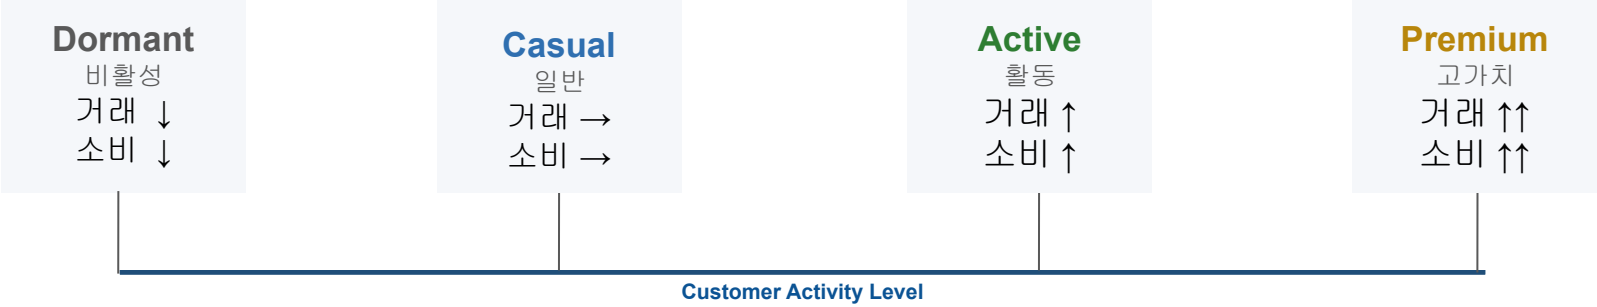

6. 고객 세그먼트 및 분석

Dormant

행동	위험
거래 빈도 ↓ 거래 금액 ↓ 미사용 기간 ↑	이탈 가능성 ↑ 경쟁 카드로 이동 위협 비활성 고객 증가 위험
제품 방향	**KPI**
진입형 카드 저/무연회비 자동납부 혜택	30일 활성화율 90일 유지율

Dormant 고객 = 재활성화 전략의 핵심 타깃

6. 고객 세그먼트 및 분석

Casual

행동	위험
거래 빈도 → 거래 금액 → 카드 이용 지속	주사용 카드 전환 실패 가능성 경쟁 카드로 분산 이용 가능 이용 습관 고착 전 단계
제품 방향	**KPI**
생활 혜택 카드 캐시백/포인트 강화 주사용 카드 전환 유도	월 이용 횟수 월 이용 금액 카드 이용 점유율

Casual 고객 = 주사용 카드 전환 잠재 고객

6. 고객 세그먼트 및 분석

Active

행동	위험
거래 빈도 ↑ 거래 금액 ↑ 카드 이용 활동 활발	경쟁 카드로 이동 가능 혜택 체감 저하 시 이탈 가능 상위 카드 전환 기회 존재
제품 방향	**KPI**
리워드 강화 카드 고액 결제 혜택 상위 카드 업셀 전략	월 이용 금액 고액 결제 비중 업셀 전환율

Active 고객 = 상위 카드 업셀 핵심 대상

6. 고객 세그먼트 및 분석

Premium

행동	위험
거래 빈도 ↑ 거래 금액 ↑ 신용 한도 ↑	혜택 경쟁 심화 프리미엄 카드 이동 가능성 고가치 고객 이탈 리스크
제품 방향	**KPI**
프리미엄 카드 마일리지 / 여행 혜택 VIP 서비스	연간 이용 금액 고객 유지율 ARPU (고객당 수익)

Premium 고객 = 카드사 수익의 핵심 고객군

7. 카드 상품 라인업 전략

카드 상품 라인업 구조

- Entry → Core Reward → Premium
- 고객 가치 상승에 따라 업셀 구조 형성

수익 구조

- 카드 이용 확대 → 가맹점 수수료 및 이용액 기반 수익
- **Installment(할부) / Revolving** → 카드사의 금융 수익 구조

7. 카드 상품 라인업 전략

리워드 기반 카드

콘셉트	목적	혜택 골자	가격 / 조건	자격 기준/ (게이팅)	리스크 통제	KPI
Entry	고객 활성화	첫 결제 보너스, 자동납부 혜택, 웰컴 포인트	저 / 무연회비, 웰컴 혜택	신규 / 저이용 고객	낮은 초기 한도, 사용 모니터링	30일 활성화율
Cashback	일상 소비 카테고리 고정	생활 카테고리 할인 / 캐시백	실적 조건 + 월 혜택 캡	안정적 이용 패턴 고객	혜택 캡, 제휴 비용 분담	월 이용 횟수
Points	이용액 확대 / 업셀	기본 포인트 적립 + 선택 카테고리 추가 적립	실적 조건 상향, 적립 캡	일정 이용액 이상 고객	오퍼 과다 지급 방지	이용액 증가
Premium	핵심 고객 유지	여행 / 라운지 / 다이닝 혜택	고연회비 + 선택 혜택	고이용 / 고가치 고객	쿠폰형 혜택 구조	갱신율 / ARPU / 이용액

EXODIA

7. 카드 상품 라인업 전략

행동 기반 카드

콘셉트	목적	혜택 골자	가격 / 조건	자격 기준/ (게이팅)	리스크 통제	KPI
Co-brand	선호 기반 소비 확대	항공 마일리지 / 브랜드 할인	제휴 연회비 구조	브랜드 충성 고객 확보	제휴 정산 관리	제휴 이용 비중
Installment	고액 결제 장벽 완화	무 / 저이자 할부	할부 기간 / 업종별 조건	고액 결제 고객	업종별 한도 관리	할부 전환율
Revolving	상환 유연성 제공	부분 결제 / 상환 옵션	조건부 금리	일정 신용도 이상	이용률 / 연체 관리	리볼빙 이용률
Bundle / Family	고객 관계 확장	가족 / 구독 / 자동납부 혜택	번들 혜택 구조	다상품 이용 고객	혜택 누수 방지	상품 보유 수 증가

7. 카드 상품 라인업 전략

고객 세그먼트 별 전략

Segment	전략 목적	카드 상품 유형
Dormant	초기 카드 사용 활성화	Entry
Casual	생활 소비 카드 고정	Cashback
Active	이용액 확대 및 제휴 소비 유도	Points / Co-brand
Premium	고가치 고객 유지	Premium
High utilization	고사용 고객 결제 부담 완화 및 상환 유연성 제공	Revolving

7. 카드 상품 라인업 전략

하나카드 상품 라인

	Entry	Points	Premium
대표 상품	원더 카드 **2.0 FREE**	원더 카드 **2.0 LIVING**	JADE First
연회비	₩ 12,000	₩ 12,000 +₩ 7,900 (제휴)	₩ 595,000+₩ 5,000 (해외 겸용)
전월 실적	전월 실적 무관, 적립 한도 없음	전월 실적 40만원/80만원/120만원	전월 실적 200만원 ~
핵심 혜택	1. 주요 혜택: 국내외 전 가맹점 약 0.8% 무제한 청구 할인 2. 혜택 항목: **간편결제** (1.2% 할인), **마트** (2% 할인), **대중교통**(3%할인)	1.주요 혜택: 생활 밀착형 영역 최대 10% 적립 2. 혜택 항목: **생활비**, 병원, 약국,주유, 택시, 커피, 세탁에 대해 10% 청구 할인	1. 주요 혜택: 국내외 전 가맹점 최대 1.5% 하나머니 무제한 적립 2. 혜택 항목: 프리미엄 바우처(30만 원 상당 여행 + 20만 원 상당 식사), 전 세계 라운지 연 8회(동반 1인 가능)
주요 소비 타깃	2030 사회초년생 및 합리적 소비 지향층	계획적 소비를 지향하는 가계 주도층	하이엔드 라이프스타일을 향유하는 VVIP 고객

8. 결론

요약

1. 5개의 머신러닝 모델 구현

최적화를 통해 예측 정확도 상승 확인

2. 고객 이탈은 점진적 이탈

고객의 행동에서 **위험 시그널 및 숨겨진 맥락** 파악

3. 세그먼트별 고객 전략

카드 라인업 전략을 **이탈률과 수익성의 관점**으로 분석

8. 결론

한계점

1. 마스킹 데이터의 한계

- Kaggle 공개 데이터 기반 분석으로 실제 금융 데이터와 차이가 존재
- 도출된 임계치 및 전략은 **실무 적용 전 추가 검증 필요**

2. 결측치 보간 작업

- Income, Education 변수의 **Unknown 값 추정 및 보완**
- 보완 시 고객 특성 기반 이탈 영향 분석 고도화 기대

8. 결론

확장 시 기대 효과

1. 고객 생애 가치 보존 및 수수료 방어

- **리워드 기반 라인업**을 통해 고객의 일상 소비를 자사 카드로 고정
- 안정적 가맹점 수수료 수익 확보

2. 핵심 금융 수익 극대화

- **행동 기반 라인업을 통해** 고액 결제 상환 유연성 제공
- 연체 리스크 관리와 이자 수익을 극대화 하는 구조

출처

- **Kaggle – *Credit Card Customer Churn Dataset***
  https://www.kaggle.com/datasets/sakshigoyal7/credit-card-customers

- **Docker Official Documentation**
  https://docs.docker.com

- **MLflow Documentation**
  https://mlflow.org/docs/latest

- 하나 카드
  https://www.hanacard.co.kr

감사합니다

by EXODIA